

**Akadska godina:** 2024/25

**Semestar:** VI – šesti

**Predmet:** Inteligentni sistemi

**Predmetni profesor:** doc. dr. Admir Midžić

**Asistent:** asist. Una Drakulić, MA

**Studenti:** Suad Kucalović (br. indeksa: 1272)

## Teorija za završni ispit

### 1. Šta su ti inteligentni sistemi! Navesti definiciju i nekoliko primjera njihove primjene!

- Inteligentni sistemi predstavljaju računarske platforme koje integriraju metode veštačke inteligencije kako bi simulirale ljudsko donošenje odluka i rješavale kompleksne probleme. Ovi sistemi kombiniraju algoritme mašinskog učenja, obrade prirodnog jezika i robotske autonomije kako bi prilagodljivo reagirali na promjenjive uvjete. Primjeri uključuju personalizirane preporučiace sadržaja poput Netflixovog algoritma, autonomne vozilne sustave koji koriste senzore za navigaciju, te medicinske dijagnostičke alate koji analiziraju medicinske slike sa preciznošću nadmašujući ljudsku.

### 2. Šta je to prostor stanja, a šta veličina prostora stanja?

- Prostor stanja predstavlja sve moguće konfiguracije koje sistem može zauzeti tokom rješavanja problema, gdje svako stanje opisuje jedinstvenu situaciju. Veličina prostora stanja odnosi se na ukupan broj tih mogućnosti i direktno utječe na složenost problema - šah, na primjer, ima oko  $10^{120}$  stanja što objašnjava izazovnost njegovog modeliranja. Ova konceptualizacija ključna je za dizajn algoritama pretraživanja jer određuje izvodljivost i strategiju rješavanja.

### 3. Slijepo pretraživanje - ukratko objasniti!

- Slijepo pretraživanje predstavlja strategiju koja ne koristi dodatne informacije o problemu, već sistematski iscrpljuje sve mogućnosti bez prioritizacije. Ove metode, poput pretraživanja u širinu ili dubinu, garantuju pronalazak rješenja ako ono postoji, ali postaju neučinkovite u velikim prostorima stanja. Njihova glavna vrijednost leži u jednostavnosti implementacije i pouzdanosti pri rješavanju osnovnih problema gdje su heuristike nedostupne.

### 4. Pretraživanje u širinu - ukratko objasniti!

- Algoritam pretraživanja u širinu istražuje sve čvorove na istoj razini prije nego što pređe na sljedeći nivo, koristeći FIFO red za upravljanje čvorovima. Ova metoda garantuje pronalazak najkraćeg puta u nerazgranatim grafovima, što je čini idealnom za probleme poput navigacije kroz mrežu gradova. Međutim, memorijski zahtjevi eksponencijalno rastu s dubinom što ograničava primjenu na velike prostore.

### 5. Pretraživanje u dubinu ukratko objasniti!

- Suprotno BFS-u, pretraživanje u dubinu prioritizira istraživanje jednog pravca do maksimalne dubine prije povratka, koristeći LIFO stog. Ova karakteristika čini ga memorijski efikasnijim, ali riskira zaglavljivanje u beskonačnim granama i ne garantuje optimalnost rješenja. DFS posebno vrijedi za probleme gdje se rješenje nalazi duboko u stablu, kao što je rješavanje slagalica sa više koraka.

### 6. Informirano pretraživanje - ukratko objasniti!

- Informirano pretraživanje koristi heurističke funkcije koje procjenjuju udaljenost do cilja, usmjeravajući pretragu ka obećavajućim oblastima. A\* algoritam, najpoznatiji predstavnik, kombinira stvarnu cijenu puta s heurističkom procjenom, garantujući optimalnost uz dopustive heuristike. Ove metode dramatično poboljšavaju efikasnost u odnosu na slijepu strategiju, posebno u prostorima sa dobrom heuristikom poput geografskih navigacionih problema.

### 7. ...

**8. Šta je to naivni Bayes-ov klasifikator - ukratko objasniti!**

- Naivni Bayes temelji se na Bayesovoj teoremi uz pretpostavku nezavisnosti značajki, što mu omogućuje brzu i efikasnu klasifikaciju iako je ova pretpostavka često nerealna. Unatoč tome, pokazuje iznenađujuću učinkovitost u tekstualnoj analizi, posebno u filtriranju neželjene pošte gdje nezavisnost riječi nije strogo ispunjena. Njegova prednost je jednostavnost implementacije i mogućnost rada s malim skupovima podataka.

**9. Šta su to klasteri i koje metode/tehnike se najčešće koriste za analizu klastera?**

- Klasteriranje grupira slične instance u skupine bez prethodno definiranih labela, otkrivajući prirodne strukture u podacima. K-sredina, najpopularnija metoda, iterativno pronalazi centroide koji minimiziraju unutarklasternu varijansu, dok hijerarhijsko klasteriranje gradi dendrogram omogućujući analizu na više nivoa sličnosti. Ove tehnike imaju široku primjenu od segmentacije korisnika do bioinformatike, ali zahtijevaju pažljiv odabir mjera sličnosti i algoritama.

**10. Šta su to stabla odluke (Decision Tree) - ukratko objasniti!**

- Stabla odluke modeliraju proces donošenja odluka kroz hijerarhijsku strukturu if-then pravila, gdje svaki čvor predstavlja test neke značajke. Ova transparentnost čini ih posebno korisnima u domenima gdje je objašnjivost kritična, kao što su medicinska dijagnostika ili kreditno ocjenjivanje. Iako skloni prenaučenosti, tehnike kao što su ograda i ograničavanje dubine omogućuju njihovu primjenu na složenije probleme bez gubitka interpretabilnosti.

**11. ...**

**12. Šta su to neuronske mreže?**

- Neuronske mreže su računarski sistemi inspirirani biološkim neuronima, sastavljeni od međusobno povezanih slojeva koji zajedno obrađuju informacije. Svaki neuron prima ulazne signale, množi ih s težinama, sumira i primjenjuje nelinearnu aktivacijsku funkciju. Ključna snaga ovih mreža leži u njihovoj sposobnosti da uče hijerarhijske reprezentacije podataka - od osnovnih značajki u nižim slojevima do apstraktnih koncepata u dubokim slojevima. Ova karakteristika čini ih nezamjenjivim za kompleksne probleme poput prepoznavanja slika i prirodnog jezika.

**13. Vještačka neuronska mreža i Van Neumannova arhitektura - poređenje!**

- Van Neumannova arhitektura, temelj klasičnih računara, temelji se na sekvencijalnoj obradi instrukcija i jasnoj podjeli na procesor i memoriju. Nasuprot tome, neuronske mreže implementiraju paralelnu distribuiranu obradu gdje se izračunavanja odvijaju simultano kroz mrežu povezanih neurona. Dok Van Neumannov model excelira u preciznom izvršavanju unaprijed definiranih algoritama, neuronske mreže briljiraju u adaptivnom učenju iz podataka i rješavanju problema gdje su eksplicitna pravila teška za formuliranje.

**14. Primjena vještačkih neuronskih mreža - navesti nekoliko primjera!**

- Neuronske mreže revolucionirale su brojne industrije svojom sposobnošću obrade složenih podataka. U medicini, pomažu u analizi medicinskih slika s točnošću koja nadmašuje ljudsku, dok u financijama detektiraju neuobičajene transakcije i predviđaju tržišne trendove. Autonomna vozila oslanjaju se na konvolucijske mreže za prepoznavanje objekata, dok transformatorske arhitekture omogućuju napredne sisteme za prevođenje jezika. Ove primjene demonstriraju univerzalnost neuronskih mreža u rješavanju različitih problema.

**15. TLU perceptron - skicirajte model i ukratko objasnite!**

- TLU (Threshold Logic Unit) perceptron predstavlja najjednostavniji oblik neuronske mreže s jednim slojem težina i pragom aktivacije. Radi tako što izračunava ponderiranu sumu ulaza i primjenjuje step funkciju kako bi donio binarnu odluku. Iako ograničen na linearno separabilne probleme, ovaj model postavio je temelje modernog dubokog učenja demonstrirajući kako se parametri mogu adaptirati kroz iterativno učenje. Njegova jednostavnost čini ga izvrsnim uvodom u koncepte neuronskih mreža, iako praktična primjena zahtijeva složenije arhitekture.

16. ...

**17. Objasnite algoritam kod perceptron neuronske mreže!**

- Algoritam učenja perceptrona kombinira jednostavnost sa snažnim matematičkim temeljima. Svaka iteracija uključuje propagaciju ulaza unaprijed kroz mrežu, računanje greške između predviđanja i stvarne vrijednosti, te propagaciju unazad kako bi se težine prilagodile. Ovaj osnovni mehanizam, iako razvijen 1950-ih, i danas čini srž mnogih složenijih algoritama dubokog učenja. Njegova ograničenja u rješavanju nelinearnih problema potaknula su razvoj višeslojnih perceptrona sa nelinearnim aktivacijskim funkcijama.

**18. Objasnite algoritam backpropagation (algoritam propagacije greške unazad)!**

- Backpropagation revolucionizirao je područje neuronskih mreža omogućujući efikasno učenje višeslojnih arhitektura. Algoritam pametno distribuira grešku unazad kroz mrežu koristeći lančano pravilo diferencijalnog računa, što omogućuje prilagodbu svih težina proporcionalno njihovom doprinosu ukupnoj grešci. Ovaj proces zahtijeva pažljiv odabir stope učenja i inicijalizacije težina kako bi se izbjegli problemi nestajućih gradijenata. Unatoč pojavi novijih optimizatora, backpropagation ostaje temeljna tehnika u treniranju neuronskih mreža.

**19. Kako se neuronske mreže mogu podijeliti?**

- Neuronske mreže se klasificiraju prema više kriterija, uključujući dubinu (jednoslojne vs. višeslojne), tip veza (potpuno povezane, konvolucijske) i način obrade (feedforward, rekurentne). Jednoslojne mreže ograničene su na linearne probleme, dok duboke arhitekture mogu modelirati složene nelinearne odnose. Konvolucijske mreže posebno su efikasne za prostorne podatke poput slika, dok rekurentne mreže exceliraju u obradi vremenskih serija. Ova raznolikost omogućuje odabir optimalne arhitekture za specifične probleme.

**20. Navesti bar po dva primjera statičkih, dinamičkih i neizrazitih neuronskih mreža i ukratko objasniti!**

- Statičke mreže poput višeslojnog perceptrona idealne su za klasifikaciju tabličnih podataka, dok dinamičke arhitekture poput LSTM-a obrađuju vremenski zavisne podatke. Neizrazite neuronske mreže kombiniraju prednosti fuzzy logike i neuronskih mreža za probleme s nesigurnošću. Svaki tip ima jedinstvene karakteristike: Kohonenove mreže za nesuprizirano učenje, Hopfieldove mreže za asocijativno pamćenje, dok transformerske arhitekture dominiraju u obradi prirodnog jezika. Ovaj ekosistem tehnologija omogućuje rješavanje širokog spektra problema.

**21. Šta su to jednoslojne, a šta višeslojene neuronske mreže - navesti primjer i ukratko objasniti!**

- Jednoslojne neuronske mreže, poput osnovnog perceptrona, ograničene su na rješavanje linearno separabilnih problema zbog nedostatka skrivenih slojeva. Njihova jednostavna arhitektura uključuje samo ulazni i izlazni sloj, što ih čini brzim za treniranje, ali nesposobnim za modeliranje složenih nelinearnih odnosa. Nasuprot tome, višeslojne mreže s jednim ili više skrivenih slojeva mogu naučiti hijerarhijske reprezentacije podataka, što im omogućuje rješavanje znatno složenijih problema. Ključna prednost dubokih arhitektura je njihova sposobnost automatskog izdvajanja značajki, ali za cijenu veće računske složenosti i potrebe za većim skupovima podataka.

**22. Kako se rad neuronskih mreža može prikazati - koje su faze rada i karakteristike sve od faza?**

- Proces rada neuronskih mreža obuhvata tri ključne faze: ulaznu obradu, samu obradu podataka kroz mrežu i generiranje izlaza. U ulaznoj fazi podaci se normaliziraju i pripremaju za obradu, što može uključivati skaliranje, kodiranje kategoričkih varijabli ili augmentaciju. Tokom faze obrade, podaci prolaze kroz slojeve mreže gdje se izvode linearne transformacije i nelinearne aktivacije, pri čemu se težine iterativno prilagođavaju kroz proces učenja. Izlazna faza uključuje interpretaciju rezultata, evaluaciju performansi i potencijalno fino podešavanje modela kako bi se poboljšala njegova sposobnost generalizacije.

**23. Omjer raspodjele podataka kod treninga, validacije i testiranja, te mogući problemi u ovom procesu (generalizacija, pretreniranost) - objasniti!**

- Pravilna podjela podataka na trening, validacioni i test skup temeljna je za uspješno treniranje neuronskih mreža. Tipična podjela uključuje 70% podataka za treniranje, 15% za validaciju i 15% za testiranje. Glavni izazovi u procesu učenja uključuju prenaučenosť (overfitting), gdje model postiže izvrsne rezultate na trening podacima ali slabe na novim podacima, i podnaučenosť (underfitting), kada model ne može uhvatiti osnovne obrasce u podacima. Tehnike poput regularizacije, dropouta i rane zaustavke koriste se za ublažavanje ovih problema i poboljšanje generalizacijske sposobnosti modela.

**24. Algoritmi učenja kod neuronskih mreža - navesti bar dva primjera i objasniti!**

- Postoji nekoliko ključnih algoritama za optimizaciju parametara neuronskih mreža, svaki sa svojim prednostima i ograničenjima. Stohastički gradijentni spust (SGD) predstavlja osnovni algoritam koji ažurira težine u smjeru negativnog gradijenta funkcije gubitka. Naprednije varijante poput Adam kombiniraju prednosti RMSprop i momentuma, adaptivno podešavajući stopu učenja za svaki parametar. Adam je posebno popularan zbog svoje robusnosti i sposobnosti brze konvergencije, što ga čini izborom broj jedan za mnoge praktične primjene dubokog učenja.

**25. Šta je to podržano učenje - ukratko objasniti!**

- Podržano učenje neuronskih mreža temelji se na korištenju označenih podataka gdje model uči mapiranje između ulaza i poznatih izlaza. Ovaj pristup zahtijeva dobro pripremljen skup podataka s preciznim oznakama i uključuje definiranje funkcije gubitka koja kvantificira odstupanje između predviđanja i stvarnih vrijednosti. Kroz iterativni proces propagacije unaprijed i unazad, model postupno poboljšava svoju sposobnost predviđanja. Podržano učenje posebno je uspješno u kombinaciji s dubokim neuronskim mrežama, gdje se pokazalo izuzetno efektivnim za širok spektar problema od klasifikacije slika do obrade prirodnog jezika.

**26. Šta su to aktivacijske funkcije kod neuronskih mreža i koje su najčešće korištene kod MLP mreža?**

- Aktivacijske funkcije uvode nelinearnost u neuronske mreže, što im omogućuje da uče složene obrasce u podacima. Sigmoidna funkcija, koja preslikava ulaze u interval (0,1), bila je popularna u ranim mrežama ali pati od problema nestajućih gradijenata. ReLU (Rectified Linear Unit) funkcija postala je standardni izbor za skrivene slojeve zbog svoje jednostavnosti i efikasnosti u sprječavanju problema nestajućih gradijenata. Softmax funkcija, koja normalizira izlaze u distribuciju vjerojatnosti, obično se koristi u izlaznom sloju za probleme višeklasne klasifikacije. Pravilan izbor aktivacijskih funkcija ključan je za performanse mreže.

**27. Objasniti princip rada Hopfield-ove neuronske mreže!**

- Hopfieldove mreže predstavljaju tip rekurentne neuronske mreže koja se koristi kao asocijativna memorija, sposobna za pamćenje i rekonstrukciju uzoraka. Ove mreže karakteriziraju potpuno povezani neuroni sa simetričnim težinama i diskretnim izlazima. Hopfieldova mreža teži minimizaciji svoje energetske funkcije, stabilizirajući se u lokalnim minimumima koji odgovaraju zapamćenim uzorcima. Primjene uključuju rekonstrukciju nepotpunih ili oštećenih podataka, optimizaciju problema i modeliranje neuronskih procesa u neuroznanosti. Međutim, ograničeni kapacitet pamćenja i problem lažnih minimuma ograničavaju njihovu praktičnu upotrebu.

**28. Objasniti princip rada Elman-ove neuronske mreže!**

- Elmanove mreže predstavljaju specijalizirani tip rekurentne neuronske mreže koja uključuje kontekstne čvorove za pohranu prethodnih aktivacija skrivenog sloja. Ova arhitektura omogućuje mreži da održi određenu vremensku zavisnost, što je čini pogodnom za obradu sekvencijalnih podataka poput vremenskih serija ili prirodnog jezika. Ključna karakteristika Elmanove mreže je povratna veza iz skrivenog sloja u posebne kontekstne čvorove, koji zatim te informacije koriste u

sljedećem koraku obrade. Ove mreže pokazuju dobre rezultate u predviđanju vremenskih serija i modeliranju dinamičkih sistema.

**29. Objasniti princip rada NARX neuronske mreže!**

- NARX (Nonlinear Autoregressive with Exogenous Inputs) neuronske mreže specijalizirane su za modeliranje nelinearnih dinamičkih sistema s vanjskim ulazima. Ove mreže eksplicitno koriste prošle vrijednosti izlaza kao ulaze u trenutnom koraku, što im daje jedinstvenu sposobnost modeliranja složenih vremenskih ovisnosti. NARX mreže pokazuju bolju stabilnost u odnosu na standardne rekurentne mreže i efikasnije učenje zahvaljujući eksplicitnoj strukturi povratnih veza. Primjene uključuju predviđanje financijskih vremenskih serija, modeliranje industrijskih procesa i analizu potrošnje energije.

**30. Kako se vrši testiranje neuronskih mreža, koji podaci se koriste, kako su rapoređeni u odnosu na ukupni postotak podataka!**

- Testiranje neuronskih mreža zahtijeva strogo odvajanje test skupa podataka koji se nikada ne koristi tokom treniranja ili validacije. Ključni aspekti uključuju korištenje odgovarajućih metrika evaluacije (npr. tačnost, preciznost, recall), analizu grešaka kako bi se identificirale slabosti modela, i testiranje robustnosti na šum i iznenađujuće ulaze. Križana validacija koristi se kada je skup podataka ograničen, dok se praćenje distribucije podataka osigurava konzistentnost između treninga i testiranja. Dokumentiranje svih pretpostavki i ograničenja testnog procesa ključno je za reproduktivnost rezultata.

**31. Definicija heuristike i metaheuristike! Objasniti razliku između ova dva pojma.**

- Heuristike predstavljaju praktična pravila ili strategije koje omogućuju brže rješavanje složenih problema kada su klasične metode neprikladne. U kontekstu neuronskih mreža, heurističke metode često se koriste za inicijalizaciju težina, odabir arhitekture mreže ili podešavanje hiperparametara. Metaheuristike su općenitiji optimizacioni okviri koji ne ovise o specifičnostima problema, poput genetskih algoritama ili optimizacije rojem čestica. Ove tehnike posebno su vrijedne za složene probleme gdje gradijentne metode ne daju zadovoljavajuće rezultate, jer istražuju prostor rješenja na globalniji način.

**32. Podjela algoritama evolucionog računarstva! Ukratko objasniti!**

- Evoluciono računarstvo obuhvata skup tehnika inspiriranih biološkom evolucijom, uključujući genetske algoritme, evolucijske strategije i genetsko programiranje. Ove metode simuliraju procese prirodne selekcije, mutacije i rekombinacije kako bi pronašle optimalna rješenja. U području neuronskih mreža, evolucione tehnike koriste se za optimizaciju arhitekture (neuroevolucija), učenje težina i kombinaciju više modela. Primjene uključuju igre, robotiku i autonomne sisteme gdje tradicionalne metode nailaze na ograničenja, posebno u slučajevima kada funkcija gubitka nije glatka ili diferencibilna.

**33. Definicija optimizacije i kako se dijele problemi optimizacije!**

- Optimizacija predstavlja proces pronalaženja najboljeg rješenja određenog problema unutar datog skupa mogućnosti, pri čemu se "najbolje" definira kroz ciljnu funkciju koju želimo minimizirati ili maksimizirati. U kontekstu neuronskih mreža, optimizacija se najčešće odnosi na pronalaženje optimalnih vrijednosti težina koje minimiziraju funkciju gubitka, ali može obuhvatati i optimizaciju hiperparametara ili čitave arhitekture mreže. Problemi optimizacije dijele se prema više kriterija - na linearne i nelinearne ovisno o prirodi ciljne funkcije i ograničenja, na konveksne i nekonveksne prema obliku prostora rješenja, te na unimodalne i multimodalne ovisno o broju lokalnih optimuma. Posebno značajna podjela razlikuje determinističke od stohastičkih metoda optimizacije, gdje prve garantuju isti rezultat za iste početne uvjete, dok druge koriste element slučajnosti kako bi izbjegle zarobljavanje u lokalnim optimumima. U praksi se često koriste hibridni pristupi koji kombiniraju

prednosti različitih metoda, posebno pri rješavanju složenih problema dubokog učenja gdje prostor pretraživanja može biti izuzetno kompleksan i visokodimenzionalan.