Akademska godina: 2024/25
Semestar: VI – šesti
Predmet: Inteligentni sistemi
Predmetni profesor: doc. dr. Admir Midžić
Asistent: v. asist. Una Drakulić, MA
Student: Hadis Mahmutović (br. indeksa: 1271)

Teorija za II kolokvij

1. **Šta je to genetički algoritam i koja je njegova osnovna namjena (za rješavanje kojih problema se koristi)?**
   - Genetički algoritam je optimizacioni algoritam inspirisan procesima prirodne selekcije i genetike, kao što su ukrštanje, mutacija i selekcija jedinki. Spada u grupu evolutivnih algoritama i koristi se za rješavanje složenih problema kod kojih klasične metode optimizacije nisu efikasne.
   - Genetički algoritam se koristi za pronalaženje približno najboljeg rješenja (optimuma) u problemima gdje:
     - prostor rješenja je veoma veliki ili kompleksan
     - problem nije moguće efikasno riješiti analitičkim metodama
     - postoji više mogućih rješenja i potrebno je pronaći ono koje je "najbolje" prema nekoj funkciji cilja
2. **Eliminacijski genetički algoritam (Steady State Genetic Algorithm)! Objasniti princip rada koristeći pseudokod!**
   - Princip rada: Kod eliminacijskog G.A. umjesto zamjene cijele populacije novom, samo nekoliko jedinki se mijenja po iteraciji (najčešće 1 ili 2). Najlošije jedinke se zamjenjuju boljim potomstvom.
   - Pseudokod:
     - Inicijalizuj populaciju P
     - dok nije ispunjen kriterij zaustavljanja:
       - Odaberi dvije roditeljske jedinke iz P (npr. turnirski odabir)
       - Primijeni ukrštanje i mutaciju => dobij dijete
       - Procijeni kvalitet djeteta (fitness)
       - Zamijeni najlošiju jedinku u P novim djetetom ako je dijete bolje
3. **Generacijski genetički algoriratam! Objasniti princip rada koristeći pseudokod!**
   - Generacijski genetički algoritam je izvedba kod koje je na početku svake iteracije populacija roditelja fiksirana. Iz te populacije biraju se roditelji koji križanjem i mutacijom stvaraju djecu koja se pohranjuju u pomoćnu privremenu populaciju. Postupak se radi sve do trenutka dok u populaciji djece nema jednak broj jedinki koliko ih je i u roditeljskoj populaciji. Kada se to dogodi, roditeljska se populacija briše a stvorena populacija djece promovira se u roditelje. Taj trenutak označava smjenu generacije nakon čega se postupak ciklički ponavlja.
   - Pseudokod:
     - Generiraj slučajnu populaciju mozgova od VEL_POP jedinki; evaluiraj svaki.
     - Ponavljaj sve dok nije kraj:
       - Inicijaliziraj pomoćnu populaciju na praznu.
       - Ponavljaj sve dok veličina pomoćne populacije ne postane jednaka veličini populacije roditelja
         - Odaberi dva roditelja iz populacije roditelja
         - Dijete = Križaj roditelje + Mutacija
         - Vrednuj dijete

            - Ubaci ga u pomoćnu populaciju
        - Obriši populaciju roditelja
        - Promoviraj pomoćnu populaciju u populaciju roditelja
- Kod generacijskog genetskog algoritma eventualno dobro dijete ne može se odmah iskoristiti; ono mora pričekati dok se ne završi čitava generacija.

4. **Definiraj i objasni pojmove Jedinka (engl. individual) i Fenotip (engl. phenotype) kod genetičkog algoritma!**
   - Jedinka: Pojedinačno rješenje problema u okviru populacije (npr. niz brojeva, niz gena).
   - Fenotip: Vidljiva interpretacija jedinke – kako to rješenje "izgleda" u stvarnom problemu (npr. konkretna ruta, raspored, raspored sati).
5. **Definiraj i objasni pojmove Genotip (engl. genotype) i Hromozom (engl. chromosome):**
   - Genotip: Interna struktura jedinke – zapis njenog rješenja u obliku niza (npr. binarni niz: 110101).
   - Hromozom: Drugi naziv za genotip – često korišten u kontekstu ukrštanja i mutacije.
6. **Definiraj i objasni pojmove Populacija (engl. population): i Generacija (engl. generation): .**
   - Populacija: Skup svih jedinki u nekom trenutku algoritma.
   - Generacija: Iteracija algoritma, tj. svaka nova populacija nastala nakon ukrštanja i mutacije.
7. **Mravlji algoritam! Objasniti princip rada koristeći pseudokod!**
   - Algoritam radi s populacijom od $\boldsymbol{m}$ mrava, pri čemu u petlji ponavlja sljedeće. Svih $\boldsymbol{m}$ mrava pusti se da stvore rješenja, i ta se rješenja vrednuju (izračunaju se dužine puteva). Pri tome, svaki mrav prilikom izgradnje pamti do tada pređeni put, i kada treba birati u koji će sljedeći čvor krenuti, automatski odbacuje čvorove kroz koje je već prošao (skupovi $\boldsymbol{N_i^k}$). Tek kada je svih $\boldsymbol{m}$ mrava stvorilo prijedloge rješenja, odabire se $\boldsymbol{n} \leq \boldsymbol{m}$ mrava koji će obaviti ažuriranje feromonskih tragova. Pri tome $\boldsymbol{n}$ može biti jednak $\boldsymbol{m}$, što znači da će svi mravi ažurirati feromonske tragove. Kako se takav pristup pokazao kao loša praksa, bolje je pustiti samo bolji podskup, ili čak samo najboljeg mrava da obavi ažuriranje. Potom se primjenjuje postupak isparavanja feromona, i sve se ciklički ponavlja.
   - Pseudokod:
     - Ponavljaj dok nije kraj
       - Ponovi za svakog mrava
         - Stvori rješenje
         - Vrednuj rješenje
       - Kraj ponovi
       - Odaberi podskup mrava
       - Ponovi za odabrane mrave
         - Ažuriraj feromonske tragove
       - Kraj ponovi
     - Kraj ponavljanja
8. **Šta je to fuzzy broj, a šta je to fuzzy skup (kako se može definirati i prikazati)?**
   - Fuzzy broj je posebna vrsta fuzzy skupa koji opisuje nepreciznu brojčanu vrijednost. Na primjer, „broj oko 5“ nije tačno 5, ali uključuje i 4.8, 5.2, možda i 4 ili 6, ali sa različitim stepenima pripadnosti.
   - Dakle, fuzzy broj je definisan funkcijom pripadnosti nad realnim brojevima koja mora biti:
     - Normalizirana (ima barem jedan član s pripadnošću 1),
     - Konveksna (nema „rupa“ u sredini),
     - Najčešće ima jedan vrh (modalna vrijednost).

- Fuzzy skup općenito označava skup čiji elementi mogu pripadati djelimično, tj. sa stepenom pripadnosti između 0 i 1. Prikazuje se funkcijom pripadnosti μ(x), a često grafički – npr. trokutasta ili trapezna funkcija.

9. **Kako se definira jednakost fuzzy skupova, a kako podskup fuzzy skupa?**
   - Dva fuzzy skupa $\boldsymbol{A}$ i $\boldsymbol{B}$ su jednaki ako za svaki element x iz univerzalnog skupa $\boldsymbol{U}$ vrijedi: $\boldsymbol{\mu A}(\boldsymbol{x}) = \boldsymbol{\mu B}(\boldsymbol{x}), \quad \forall \boldsymbol{x} \in \boldsymbol{U}$.
   - $\boldsymbol{A}$ je podskup od $\boldsymbol{B}$ ($\boldsymbol{A} \subseteq \boldsymbol{B}$) ako vrijedi: $\boldsymbol{\mu A}(\boldsymbol{x}) \leq \boldsymbol{\mu B}(\boldsymbol{x}), \quad \forall \boldsymbol{x} \in \boldsymbol{U}$.
   - Drugim riječima, svaki član A mora imati pripadnost koja nije veća nego u B.

10. **Kako se definira jezgra fuzzy skupa, i šta je to skup podrške fuzzy skupa? Treba definirati fuzzy skup "brojevi oko 5" i potom odrediti jezgru, podršku i visinu tog skupa. Je li to normaliziran skup?**
    - Jezgra fuzzy skupa $\boldsymbol{A}$ je podskup univerzalnog skupa (dakle klasični skup) sa svojstvom $\boldsymbol{\mu A}(\boldsymbol{x}) = \boldsymbol{1}$, tj. $\boldsymbol{core}(\boldsymbol{A}) = \{\boldsymbol{x} \in \boldsymbol{U} \mid \boldsymbol{\mu A}(\boldsymbol{x}) = \boldsymbol{1}\}$
    - Recimo da fuzzy skup izgleda ovako:
      A = { (3, 0.2), (4, 0.6), (5, 1.0), (6, 0.6), (7, 0.2) }
    - Jezgra (core): svi elementi gdje je μ(x) = 1 → ovdje je to {5}
    - Podrška (support): svi elementi gdje je μ(x) > 0 → {3, 4, 5, 6, 7}
    - Visina (height): maksimalna vrijednost μ(x) → height = 1.0
    - Da li je normaliziran? Da, jer postoji barem jedan element (5) s pripadnošću 1.

11. **Šta je to prazan fuzzy skup - kako se definira?**
    - Prazan skup ∅ je skup sa svojstvom $\boldsymbol{\mu_{\emptyset}}(\boldsymbol{x}) = \boldsymbol{0}, \quad \forall \boldsymbol{x} \in \boldsymbol{U}$.

12. **Šta je to visina fuzzy skupa, a šta je to centar fuzzy skupa?**
    - Visina fuzzy skupa $\boldsymbol{A}$ je maksimalna vrijednost funkcije pripadnosti $\boldsymbol{\mu A}(\boldsymbol{x})$, tj. $\boldsymbol{hgt}(\boldsymbol{A}) = \mathbf{max}_{\boldsymbol{x} \in \boldsymbol{U}} \, \boldsymbol{\mu_A}(\boldsymbol{x})$.
    - Ako je srednja vrijednost svih tačaka u kojima funkcija pripadnosti fuzzy skupa $\boldsymbol{A}$ poprima maksimalnu vrijednost konačna, tada je ta vrijednost centar. Ako je ta srednja vrijednost jednaka pozitivnoj (negativnoj) beskonačnosti, tada se kao centar uzima najmanja (najveća) tačka u kojoj funkcija pripadnosti poprima maksimalnu vrijednost.

13. **Kako izgleda grafička reprezentacija fuzzy skupa? Objasniti na bar dva primjera!**
    - Fuzzy skup se može grafički prikazati pomoću funkcije pripadnosti (membership function), koja za svaku vrijednost iz univerzalnog skupa prikazuje stepen pripadnosti (vrijednost između $\mathbf{0}$ i $\mathbf{1}$). Na grafu se obično na $\boldsymbol{x}$-osi prikazuje vrijednost elemenata iz univerzuma, a na $\boldsymbol{y}$-osi pripadnost ($\boldsymbol{\mu}(\boldsymbol{x})$) tim elementima.
    - Primjer 1: Fuzzy skup „brojevi oko 5“
    - Univerzalni skup: $\boldsymbol{U} = \{\mathbf{1}, \mathbf{2}, \ldots, \mathbf{9}\}$
    - Fuzzy skup $\boldsymbol{A}$:
    - $\boldsymbol{A} = \mathbf{0/1} + \mathbf{0.2/2} + \mathbf{0.5/3} + \mathbf{0.8/4} + \mathbf{1/5} + \mathbf{0.8/6} + \mathbf{0.5/7} + \mathbf{0.2/8} + \mathbf{0/9}$
    - To znači:
      - Broj $\mathbf{5}$ ima maksimalnu pripadnost ($\mathbf{1}$), jer je tačno “oko $\mathbf{5}$”
      - Brojevi $\mathbf{4}$ i $\mathbf{6}$ imaju visoku pripadnost ($\mathbf{0.8}$), jer su blizu $\mathbf{5}$
      - Brojevi dalje od $\mathbf{5}$ imaju manju pripadnost, dok krajnji ($\mathbf{1}$ i $\mathbf{9}$) nemaju nikakvu pripadnost ($\mathbf{0}$)
    - Grafički prikaz:

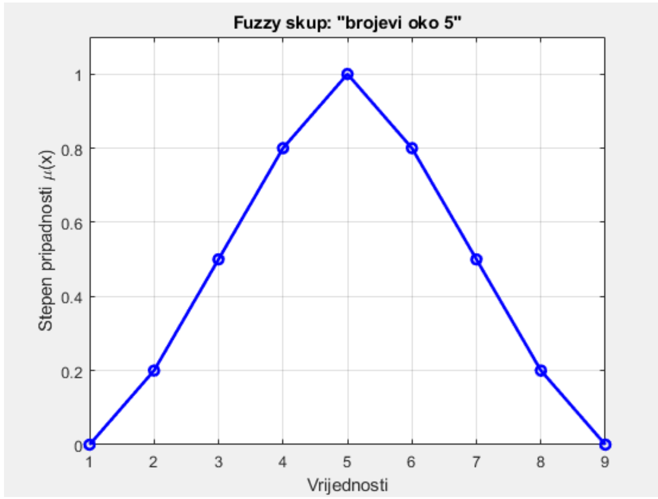

- Ovo se često zove trokutasta funkcija pripadnosti.
- Primjer 2: Fuzzy skup „temperatura je visoka“
- Univerzum: $\boldsymbol{U} = \{\mathbf{0°}\boldsymbol{C}, \mathbf{10°}\boldsymbol{C}, \ldots, \mathbf{40°}\boldsymbol{C}\}$
- Fuzzy skup $\boldsymbol{B}$ može biti definiran kao:
- $\boldsymbol{\mu}(\mathbf{0°}\boldsymbol{C}) = \mathbf{0}$
- $\boldsymbol{\mu}(\mathbf{20°}\boldsymbol{C}) = \mathbf{0.2}$
- $\boldsymbol{\mu}(\mathbf{30°}\boldsymbol{C}) = \mathbf{0.6}$
- $\boldsymbol{\mu}(\mathbf{35°}\boldsymbol{C}) = \mathbf{0.9}$
- $\boldsymbol{\mu}(\mathbf{40°}\boldsymbol{C}) = \mathbf{1}$
- Ovdje vidimo da što je viša temperatura, veća je i pripadnost fuzzy skupu “visoka temperatura”.
- Grafički prikaz:

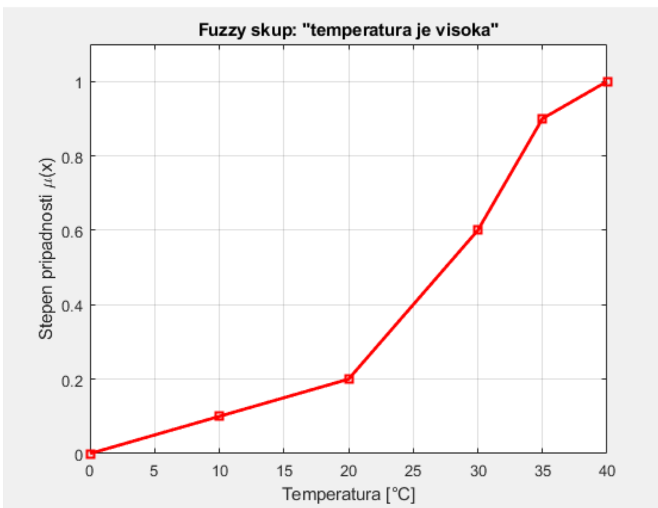

14. Šta je to alfa presjek fuzzy skupa?

- Alfa presjek fuzzy skupa $\boldsymbol{A}$ je klasični skup $\boldsymbol{A_\alpha}$ koji sadrži sve one elemente iz $\boldsymbol{A}$ koji fuzzy skupu $\boldsymbol{A}$ pripadaju barem sa stupanjem pripadnosti $\boldsymbol{\alpha}$.

15. Kako se definira unija fuzzy skupova, a kako presjek fuzzy skupova?

- Neka su $\boldsymbol{A}$ i $\boldsymbol{B}$ fuzzy skupovi definirani nad univerzalnim skupom $\boldsymbol{U}$. Unija skupova $\boldsymbol{A}$ i $\boldsymbol{B}$ je fuzzy skup $\boldsymbol{A} \cup \boldsymbol{B}$, sa svojstvom: $\forall \boldsymbol{x} \in \boldsymbol{U}\ \ \boldsymbol{\mu_{A\cup B}}(\boldsymbol{x}) = \mathbf{max}\big(\boldsymbol{\mu_A}(\boldsymbol{x}), \boldsymbol{\mu_B}(\boldsymbol{x})\big)$, odnosno
$$\boldsymbol{A} \cup \boldsymbol{B} = \left\{\big(\boldsymbol{x};\ \boldsymbol{\mu_{A\cup B}}(\boldsymbol{x})\big) \mid \boldsymbol{x} \in \boldsymbol{U}, \boldsymbol{\mu_{A\cup B}}(\boldsymbol{x}) = \mathbf{max}\big(\boldsymbol{\mu_A}(\boldsymbol{x}), \boldsymbol{\mu_B}(\boldsymbol{x})\big)\right\}$$

- Neka su $\boldsymbol{A}$ i $\boldsymbol{B}$ neizraziti skupovi definirani nad univerzalnim skupom $\boldsymbol{U}$. Presjek skupova $\boldsymbol{A}$ i $\boldsymbol{B}$ je neizrazit skup $\boldsymbol{A} \cap \boldsymbol{B}$, sa svojstvom: $\forall \boldsymbol{x} \in \boldsymbol{U}\ \ \boldsymbol{\mu_{A\cap B}(x)} = \mathbf{min}\left(\boldsymbol{\mu_A(x)}, \boldsymbol{\mu_B(x)}\right)$, odnosno
$$\boldsymbol{A} \cap \boldsymbol{B} = \left\{\left(\boldsymbol{x};\ \boldsymbol{\mu_{A\cap B}(x)}\right) \mid \boldsymbol{x} \in \boldsymbol{U}, \boldsymbol{\mu_{A\cap B}(x)} = \mathbf{min}\left(\boldsymbol{\mu_A(x)}, \boldsymbol{\mu_B(x)}\right)\right\}$$

16. Šta je to komplement fuzzy skupa?

- Neka je $\boldsymbol{A}$ fuzzy skup definiran nad univerzalnim skupom $\boldsymbol{U}$. Komplement skupa $\boldsymbol{A}$ je fuzzy skup $-\boldsymbol{A}$, sa svojstvom: $\forall \boldsymbol{x} \in \boldsymbol{U}\ \ \boldsymbol{\mu_{-A}(x)} = \mathbf{1} - \boldsymbol{\mu_A(x)}$, odnosno:
$$-\boldsymbol{A} = \left\{\left(\boldsymbol{x};\ \boldsymbol{\mu_{-A}(x)}\right) \mid \boldsymbol{x} \in \boldsymbol{U},\ \boldsymbol{\mu_{-A}(x)} = \mathbf{1} - \boldsymbol{\mu_A(x)}\right\}$$

17. Šta je to lingvistička (jezična) varijabla?

- Jezična varijabla je uređena petorka $(\boldsymbol{X}, \boldsymbol{T_X}, \boldsymbol{U}, \boldsymbol{G}, \boldsymbol{M_X})$, gdje je:
- $\boldsymbol{X}$ – naziv jezične varijable
- $\boldsymbol{T_X}$ – skup jezičnih vrijednosti koje jezična varijabla može poprimiti
- $\boldsymbol{U}$ – stvarna fizička domena u kojoj elementi iz $\boldsymbol{T_X}$ poprimaju numeričke vrijednosti
- $\boldsymbol{G}$ – gramatika (odnosno skup sintaksnih pravila) koja generira skup $\boldsymbol{T_X}$ iz osnovnih termina
- $\boldsymbol{M_X}$ – semantička funkcija koja daje značenje lingvističkim izrazima. To je funkcija koja svakom elementu iz $\boldsymbol{T_X}$ pridružuje fuzzy podskup od $\boldsymbol{U}$.

18. Šta je to fuzzy relacija?

- Neka su $\boldsymbol{U_1}, \boldsymbol{U_2}, \dots, \boldsymbol{U_n}$ univerzalni skupovi. Fuzzy relacija $\boldsymbol{R}$ nad $\boldsymbol{U_1} \times \boldsymbol{U_2} \times \dots \times \boldsymbol{U_n}$ definira se kao preslikavanje $\boldsymbol{\mu_R}$: $\boldsymbol{U_1} \times \boldsymbol{U_2} \times \dots \times \boldsymbol{U_n} \rightarrow [\mathbf{0}, \mathbf{1}]$.

19. Definirajte fuzzy skupa "brojevi oko 7" nad univerzalnim skupom U = {1, 2, 3, 4, 5, 6, 7, 8, 9, 10, 11, 12, 13, 14}. Odredite njegov kardinalni i relativni kardinalni broj. Koliki bi bio njegov relativni kardinalni broj kada bismo za univerzalni skup uzeli skup cijelih brojeva?

- $\boldsymbol{U} = \{\mathbf{1}, \mathbf{2}, \dots, \mathbf{14}\}$
- $\boldsymbol{A} = \{\ (\mathbf{5}, \mathbf{0.5}), (\mathbf{6}, \mathbf{0.8}), (\mathbf{7}, \mathbf{1.0}), (\mathbf{8}, \mathbf{0.8}), (\mathbf{9}, \mathbf{0.5})\ \}$
- Kardinalni broj: Zbir vrijednosti pripadnosti: $\mathbf{0.5} + \mathbf{0.8} + \mathbf{1.0} + \mathbf{0.8} + \mathbf{0.5} = \mathbf{3.6}$
- Relativni kardinalni broj: $\mathbf{3.6} / \mathbf{14} \approx \mathbf{0.257}$
- Ako je univerzalni skup $\mathbb{Z}$ (beskonačan), relativni kardinalni broj teži ka $\mathbf{0}$ jer je fuzzy skup konačan.

20. Šta je to t-norma? Ukratko objasniti!

- t-norma označava klasu binarnih funkcija t: $[\mathbf{0}, \mathbf{1}] \times [\mathbf{0}, \mathbf{1}]$ sa svojstvima $\boldsymbol{T1} - \boldsymbol{T4}$.
- $\boldsymbol{T1}\quad \boldsymbol{t(a,b) = t(b,a)}$ komutativnost
- $\boldsymbol{T2}\quad \boldsymbol{t\left(a, t(b,c)\right) = t(t(a,b),c)}$ asocijativnost
- $\boldsymbol{T3}\quad \boldsymbol{a \leq c^b \leq d \rightarrow t(a,b) < t(c,d)}$ monotonost
- $\boldsymbol{T4}\quad \boldsymbol{t(a,1) = a,\ t(0,a) = 0}$ rubni uvjeti

21. Šta je to t-konorma? Ukratko objasniti!

- t-konorma je matematička funkcija koja u fuzzy logici modelira operaciju "ILI". Dok t-norma simulira AND (presjek), t-konorma služi za spajanje skupova u smislu "ili je A ili je B (ili oboje) istinito".
- Najčešći primjer: $\mathbf{max}(\boldsymbol{a}, \boldsymbol{b})$

22. Šta je to alfa presjek? Zadan je fuzzy skup "brojevi oko 5 ili malo veći" A=0.1/3+0.7/4+1/5 +0.9/6 +0.7/7 + 0.3/8 + 0.1/9 nad univerzalnim skupom U=1,2,3,4,5,6,7,8,9,10. Nađite alfa presjeke za svaki od članova skupa i pokađite kako se iz tih alfa presjeka može ponovo rekonstruirati fuzzy skup

- Alfa-presjek fuzzy skupa je skup svih elemenata čiji stepen pripadnosti je veći ili jednak α, gdje je α realan broj između 0 i 1. To je način da fuzzy skup "pretvorimo" u običan (crisp) skup koji uključuje samo one članove koji zadovoljavaju određeni prag pripadnosti.
- Za $\boldsymbol{\alpha} = \mathbf{0.1} \rightarrow \{\mathbf{3}, \mathbf{4}, \mathbf{5}, \mathbf{6}, \mathbf{7}, \mathbf{8}, \mathbf{9}\}$

- Za $\boldsymbol{\alpha = 0.3 \rightarrow \{4, 5, 6, 7, 8\}}$
- Za $\boldsymbol{\alpha = 0.7 \rightarrow \{4, 5, 6, 7\}}$
- Za $\boldsymbol{\alpha = 0.9 \rightarrow \{5, 6\}}$
- $\boldsymbol{Za\, \alpha = 1.0 \rightarrow \{5\}}$
- Svaki $\boldsymbol{\alpha}$-presjek predstavlja jedan "nivo". Ako se slože svi nivoi od $\boldsymbol{\alpha = 0}$ do $\boldsymbol{\alpha = 1}$, može se rekonstruisati originalni fuzzy skup tako što se za svaki element x gleda najveća vrijednost $\boldsymbol{\alpha}$ za koju se on pojavljuje u alfa-presjeku.

23. Šta je to fuzzy zaključivanje? Objasniti!
- Fuzzy zaključivanje (eng. fuzzy inference) je proces donošenja odluka koristeći pravila u formi: "Ako je ulaz A, onda je izlaz B", pri čemu su A i B fuzzy pojmovi poput "visoka temperatura" ili "mala brzina".
- Fuzzy zaključivanje omogućava da mašine donose odluke kao ljudi, uzimajući u obzir nepreciznost i nesigurnost.

24. Objasnite pojmove: fazifikacija, zaključivanje, kompozicija i defazifikacija!
- Fazifikacija – Pretvaranje konkretnih ulaznih podataka (npr. 35°C) u fuzzy vrijednosti pomoću funkcija pripadnosti (npr. "vrlo toplo" = 0.9, "toplo" = 0.3).
- Zaključivanje (inferencija) – Primjena fuzzy pravila nad fazificiranim ulazima. Svako pravilo daje svoj fuzzy izlaz.
- Kompozicija – Kombinovanje rezultata svih pravila u jedan zajednički fuzzy skup.
- Defazifikacija – Pretvaranje fuzzy izlaza u konkretnu brojčanu vrijednost.

25. Mamdani zaključivanja! Ukratko objasniti!
- Mamdani model koristi pravila u obliku: „Ako je $\boldsymbol{x}$ mali i $\boldsymbol{y}$ veliki, onda je $\boldsymbol{z}$ srednji" – gdje su sve varijable fuzzy skupovi.
- Prednosti:
    - Intuitivno razumljiv
    - Lako ga je dizajnirati ručno
- Nedostaci:
    - Zahtijeva defazifikaciju (računski skuplja)
- Koristi se kad imamo ekspertska pravila izražena jezikom, kao što je npr. u klimatizaciji, regulaciji temperature, itd.

26. Sugeno zaključivanje! Ukratko objasniti!
- Sugeno model koristi pravila čiji su izlazi funkcije ulaznih varijabli, a ne fuzzy skupovi. Na primjer: „Ako je $\boldsymbol{x}$ mali i $\boldsymbol{y}$ veliki, onda je $\boldsymbol{z = 0.5x + 0.2y + 3}$"
- Prednosti:
    - Nema potrebe za defazifikacijom
    - Brži i pogodniji za automatske kontrole
- Nedostaci:
    - Manje intuitivan
    - Teži za dizajniranje bez podataka
- Koristi se npr. u automobilskoj industriji, robotici, predikciji.

27. Objasni sličnosti razlike između automatske regulacije i vođenja?
- Automatska regulacija: Održava neku veličinu konstantnom, uprkos smetnjama. Primjer: termostat koji održava temperaturu na 22°C.
- Vođenje (navigacija): Sistem prati unaprijed zadatu putanju ili cilj. Npr. dron koji leti do određene tačke
- Sličnosti:
    - Oboje koriste povratnu spregu

    - Mogu se implementirati fuzzy metodama
- Razlike:
    - Regulacija = stabilnost, vođenje = promjena stanja
    - Regulacija reaguje na promjene, vođenje planira put

28. Šta je fuzzy upravljanje?

- To je upravljanje sistemima pomoću fuzzy logike – naročito korisno kada je sistem kompleksan, nelinearan ili teško modeliran matematički.
- Umjesto matematičkih modela koristi pravila zasnovana na ljudskom iskustvu: „Ako je greška velika, tada povećaj izlaz.“

29. Kako je građen sistem fuzzy upravljanja?

- Fuzzy sistem upravljanja se sastoji od sljedećih blokova:
    - Ulazi – npr. temperatura, brzina, greška
    - Fazifikacija – pretvara ulazne vrijednosti u fuzzy vrijednosti
    - Baza pravila – skup „Ako...onda“ pravila
    - Inferencijski mehanizam – primjenjuje pravila i kombinuje rezultate
    - Defazifikator – pretvara fuzzy izlaz u konkretnu naredbu
    - Izlaz – npr. brzina motora, intenzitet grijanja

30. Koje su osnovne komponente kontrolera na bazi fuzzy logike?

- Osnovne komponente kontrolera na bazi fuzzy logike su:
    - Fazifikator – ulazne vrijednosti → fuzzy vrijednosti
    - Baza pravila – skup pravila tipa „ako – onda“
    - Mehanizam zaključivanja – obrađuje pravila
    - Defazifikator – fuzzy vrijednost → konkretan broj

31. Kada koristiti fuzzy upravljanje?

- Fuzzy upravljanje koristimo kad:
    - Sistem je nelinearan, promjenjiv i teško modeliran
    - Nema tačne matematičke formule, ali imamo iskustvo ili ekspertno znanje
    - Potrebna je robusnost i otpornost na šumove

32. Koja je razlika između klasičnog PID upravljanja i adaptivnog fuzzy upravljanja? Navedite i opišite primjer jednog inteligentnog upravljačkog sistema!

- PID upravljanje:
    - Precizno, ali fiksno
    - Zahtijeva model sistema
    - Loše reaguje na nelinearnosti i promjene
- Fuzzy upravljanje:
    - Fleksibilnije
    - Ne zahtijeva model
    - Može se adaptirati
- Adaptivni fuzzy regulator se sam „uči“ i prilagođava ponašanju sistema.

33. Skicirajte adaptivni fuzzy regulator i objasnite njegove komponente!

-